

第四章 语法分析

- 语法分析的功能、基本任务
- 自顶向下分析法 > >
- 自底向上分析法





复习:第一章概述



编译过程是指将高级语言程序翻译为等价的目标程 序的过程。

习惯上是将编译过程划分为5个基本阶段:







4.1 语法分析概述

Syntax analysis

功能: 根据文法规则,从源程序单词符号串中识别出语法成分,并进行语法检查。

基本任务:识别符号串S是否为某语法成分。

两大类分析方法:

自顶向下分析

自底向上分析





自顶向下分析算法的基本思想为:

若
$$Z \xrightarrow{+} S$$
 则 $S \in L(G[Z])$ 否则 $S \notin L(G[Z])$

? 主要问题:

- > 左递归问题
- > 回溯问题

• 主要方法:

- 递归子程序法
- · LL分析法





自底向上分析算法的基本思想为:

若
$$Z \stackrel{+}{\underset{G[Z]}{\Leftarrow}} S$$

则 $S \in L(G[Z])$ 否则 $S \notin L(G[Z])$

- ? 主要问题:
 - > 句柄的识别问题
- 主要方法:
 - ・算符优先分析法
 - ・ LR分析法





4.2 自顶向下分析

4.2.1 自顶向下分析的一般过程

给定符号串S,若预测是某一语法成分,则可根据该语法成分的文法,设法为S构造一棵语法树,若成功,则S最终被识别为某一语法成分,即 $S \in L(G[Z])$,其中G[Z]为某语法成分的文法若不成功,则 $S \notin L(G[Z])$

• 可以通过一例子来说明语法分析过程





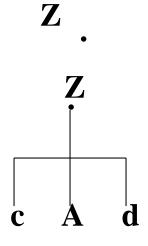
例:

S = cad G[Z]: Z := cAd A := ab|a求解 $S \in L(G[Z])$?

分析过程是设法建立一 棵语法树,使语法树的末端结 点与给定符号串相匹配。

- 1. 开始:令Z为根结点
- 2. 用Z的右部符号串去匹配输入串

完成一步推导Z⇒cAd 检查, c-c匹配 A是非终结符,将匹配任务交给A







S=cad G[Z]: Z:=cAd

A := ab|a

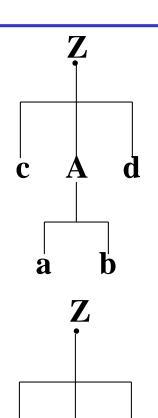
3. 选用A的右部符号串匹配输入串 A有两个右部,选第一个

> 完成进一步推导A⇒ab 检查,a-a匹配,b-d不匹配(失败) 但是还不能冒然宣布S∉L(G[Z])

4. 回溯 即砍掉A的子树 改选A的第二右部 A⇒a 检查 a-a匹配 d-d匹配

建立语法树,末端结点为cad,与输入cad相匹配, 建立了推导序列 Z⇒cAd⇒cad

 \therefore cad \in L(G(Z))







自顶向下分析方法特点:

- 1. 分析过程是带预测的,对输入符号串要预测属于什么语法成分,然后根据该语法成分的文法建立语法树。
- 2. 分析过程是一种试探过程,是尽一切办法(选用不同规则)来建立语法树的过程,由于是试探过程,难免有失败,所以分析过程需进行回溯,因此也称这种方法是带回溯的自顶向下分析方法。
- 3. 最左推导可以编写程序来实现,但带回溯的自顶向下分析方法在实际上价值不大,效率低。





4.2.2 自顶向下分析存在的问题及解决方法

1、左递归文法:

有如下文法:

令U是文法的任一非终结符,文法中有规则

U∷=U...或者U⇒ U...

这个文法是左递归的。

自顶向下分析的基本缺点是: 不能处理具有左递归性的文法

为什么?





如果在匹配输入串的过程中,假定正好轮到要用非终结符U直接匹配输入串,即要用U的右部符号串U...去匹配,为了用U...去匹配,又得用U去匹配,这样无限的循环下去将无法终止。

如果文法具有间接左递归,则也将发生上述问题,只不过环的圈子兜得更大。

要实现自顶向下分析,必须要消除文法的左递归,下面将介绍直接左递归的消除方法,在此基础上再介绍一般左递归的消除方法。





消除直接左递归

方法一,使用扩充的BNF表示来改写文法

例: (1) E := E + T | T $\Rightarrow E := T \{ + T \}$

(2) $T := T*F|T/F|F \Rightarrow T := F\{*F|/F\}$

- a. 改写以后的文法消除了左递归。
- b. 可以证明, 改写前后的文法是等价的, 表现在

$$L(G$$
改前 $) = L(G$ 改后 $)$

如何改写文法能消除左递归,又前后等价,可以给出两条规则:





规则一 (提因子)

若: U∷=xy|xw|....|xz

则可改写为: U∷=x(y|w|....|z)

若: $y=y_1y_2$, $w=y_1w_2$

 $\mathbf{U} := \mathbf{x}(\mathbf{y}_1(\mathbf{y}_2|\mathbf{w}_2)|\dots|\mathbf{z})$

若有规则: U::=x|xy

则可以改写为: $U ::= x(y|\epsilon)$

注意: 不应写成U∷=x(ε|y)

使用提因子法,不仅有助于消除直接左递归,而且有助于压缩文法的长度,使我们能更有效地分析句子。





规则二

若有文法规则: U::=x|y|.....|z|Uv

其特点是: 具有一个直接左递归的右部并位于最后, 这表明该语法类U是由x或y......或z其后随有零个 或多个v组成。

$$U \Rightarrow Uv \Rightarrow Uv vv \Rightarrow \dots$$

∴ 可以改写为U∷=(x|y|.....|z){v}

通过以上两条规则,就能消除文法的直接左递归, 并保持文法的等价性。





方法二,将左递归规则改为右递归规则

规则三

若: P::=Pα|β

则可改写为: $P : := \beta P'$

 $P' ::= \alpha P' | \varepsilon$



规则一: (提因子)

规则二: $U ::= x|y|.....|z|Uv, 则U ::= (x|y|.....|z)\{v\}$

规则三:右递归 $P ::= P\alpha | \beta$, 则 $P ::= \beta P'$, $P' ::= \alpha P' | \epsilon$

例1 E := E + T | T

右部无公因子, 所以不能

用规则一。

为了使用规则二,

令E∷=T|E+T

:由规则二可以得到

 $E:=T\{+T\}$

例2 T := T*F|T/F|F

T::=T(*F|/F) | F 规则一

T := F|T(*F|/F)

T::=F{(*F|/F)} 规则二

即T::=F{*F|/F}

右递归:

T ::= FT'

 $T' ::= *FT' | /FT' | \varepsilon$



消除一般左递归

一般左递归也可以通过改写文法予以消除。

消除所有左递归的算法:

把G的非终结符整理成某种顺序A1, A2, ·····An, ,使得:

```
A_1 ::= \delta_1 | \delta_2 | \cdots \delta_k
A_2 ::= A_1 r \cdots
```

$$A_3 ::= A_2u \mid A_1v \cdots$$



Compiler

3. 化简由2得到的文法即可。



例: 文法G[S]为

S ::= Qc|c

Q ::= Rb|b

R ::= Sa|a

该文法无直接左递归,但有间接左递归

 $S \Rightarrow Qc \Rightarrow Rbc \Rightarrow Sabc$

 \therefore S $\stackrel{+}{\Rightarrow}$ Sabc

非终结符顺序重新排列

R∷=Sa|a

Q := Rb|b

S := Qc|c



R ::= Sa|a

Q := Rb|b

S := Qc|c

- 1. 检查规则R是否存在直接左递归 R∷=Sa|a
- 2. 把R代入Q的有关选择,改写规则Q Q::=Sab|ab|b
- 3. 检查Q是否存在直接左递归
- 4. 把Q代入S的右部选择 S∷=Sabc|abc|bc|c
- 5. 消除S的直接左递归 S∷=(abc|bc|c){abc}



最后得到文法为:

 $S := (abc|bc|c){abc}$

Q∷=Sab|ab|b

R∷=Sa|a

可以看出其中关于Q和R的规则是多余的规则

∴经过压缩后 S∷=(abc|bc|c){abc}

可以证明改写前后的文法是等价的

应该指出,由于对非终结符的排序不同,最后得到的文法在形式上可能是不一样的,但是不难证明它们的等价。



```
规则一: (提因子)
```

规则二: $U := x|y|.....|z|Uv, 则U := (x|y|.....|z)\{v\}$

规则三:右递归 $P := P\alpha \mid \beta$, 则 $P := \beta P'$, $P' := \alpha P' \mid \epsilon$

1. 把G的非终结符整理成某种顺序A1, A2,An, 使得:

```
A_1 ::= \delta_1 |\delta_2| \dots \delta_k
A_2 ::= A_1 r \dots
A_3 ::= A_2 u |A_1 v \dots
```

3. 化简由2得到的文法即可。





例:

S = cad

G[Z]:

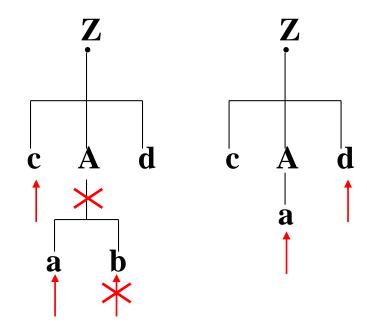
Z:=cAd

A := ab|a

求解 $S \in L(G[Z])$?

$$S = cad$$

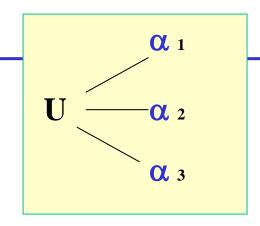
分析过程是设法建立一 棵语法树,使语法树的末端结 点与给定符号串相匹配。





2、回溯问题

什么是回溯?



分析工作要部分地或全部地退回去重做叫回溯。

造成回溯的条件:

$$\mathbf{U} ::= \alpha_1 \mid \alpha_2 \mid \alpha_3$$

文法中,对于某个非终结符号的规则其右部 有多个选择,并根据所面临的输入符号不能准确 地确定所要的选择时,就可能出现回溯。

回溯带来的问题:

严重的低效率,只有在理论上的意义而无实际意义

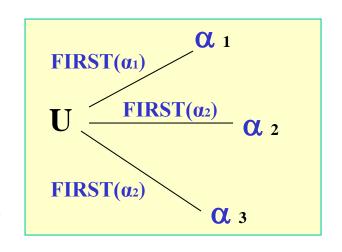


效率低的原因

- 1) 语法分析要重做
- 2) 语义处理工作要推倒重来

设文法G(不具左递归性),
$$U \in V_n$$

 $U ::= \alpha_1 | \alpha_2 | \alpha_3$



[定义] FIRST(
$$\alpha_i$$
) = { $a \mid \alpha_i \stackrel{*}{\Rightarrow} a..., a \in V_t$ }

为避免回溯,对文法的要求是:

$$FIRST(\alpha_i) \cap FIRST(\alpha_j) = \varphi \ (i \neq j)$$



消除回溯的途径:

1.改写文法

对具有多个右部的规则反复提取左因子

例1 U::=xV|xW

改写为U∷=x(V|W)

更清楚地表示为:

U := xZ

Z := V | W

 $\mathbf{U}, \mathbf{V}, \mathbf{W} \in \mathbf{V}_{n}, \mathbf{x} \in \mathbf{V}_{t^{+}}$

注意:问题到此并没有结束,还需要 进一步检查V和W的首符号是否相交

若V ::= ab | cd FIRST(V) = {a,c}

 $W := de|fg \qquad FIRST(W) = \{d,f\}$

只要不相交就可以根据输入符号确定 目标,若相交,则要代入,并再次提

取左因子。如: V::= ab W::= ac

则: Z := a(b|c)



```
FIRST(<分程序>) = {begin }
FIRST(<复合语句>) = {begin }
```

引入 <程序*>

<程序> ∷= begin <程序*>

<程序*> ::= <说明串>; <语句串> end | <语句串> end



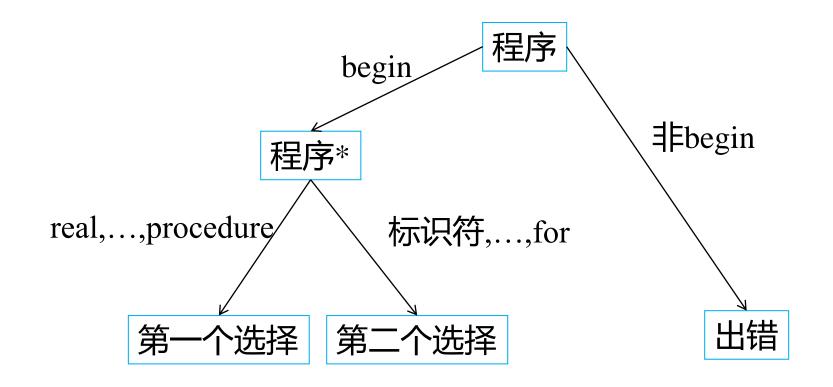
```
<程序> ∷= begin <程序*> <程序*> ∷= <说明串>; <语句串> end | <语句串> end
```

```
对于: <程序*>
FIRST( <说明串>; <语句串> end)
= {real, integer, boolean, array, function, procedure }
FIRST( <语句串>end )
= {标识符, goto, begin, if, for}
不相交。
```



<程序> ∷= begin <程序*>

<程序*>::= <说明串>; <语句串> end | <语句串> end



```
FIRST(<说明串>; <语句串> end)
= {real, integer, boolean, array, function, procedure }
FIRST(<语句串>end)
= {标识符, goto, begin, if, for}
```



2.超前扫描

当文法不满足避免回溯的条件时,即各选择的首符号相交时,可以采用超前扫描的方法,即向前侦察各输入符号串的第二个、第三个符号来确定要选择的目标

这种方法是通过向前多看几个符号来确定所选择的目标,从本质上来讲也有回溯的味道,因此比第一种方法费时,但是假读仅仅是向前侦察情况,不作任何语义处理工作。



例:

```
<程序> ::= <分程序>| <复合语句>
<分程序>::= begin<说明串>; <语句串> end
<复合语句>::= begin<语句串> end
```

这两个选择的首符号是相交的,故读到begin时并不能确定该用哪个选择,这时可采用向前假读进行侦察,此例题只需假读一次就可以确定目标。 因为<说明串>的首符集为{real, integer,, procedure} 而<语句串>的首符集为{标识符, if, for,, begin}

∴只要超前假读得到的是"说明"的首符,便是第一个选择; 若是"语句"的首符,就是第二个选择。



文法的两个条件

为了在不采取超前扫描的前提下实现不带回溯的自顶向下分析,文法需要满足两个条件:

- 1、文法是非左递归的;
- 2、对文法的任一非终结符,若其规则右部有多个选择时, 各选择 所推出的终结符号串的首符号集合要两两不相交。

```
[定义] 设文法G(不具有左递归性),U \in V_n
U ::= \alpha_1 \mid \alpha_2 \mid \alpha_3 \\ FIRST(\alpha_i) = \{a \mid \alpha_i \Rightarrow a..., a \in V_t\}
```

为避免回溯,对文法的要求是:

 $FIRST(\alpha_i) \cap FIRST(\alpha_j) = \phi \ (i \neq j)$

在上述条件下,就可以根据文法构造有效的、不带回溯的 自顶向下分析器。

> Excellence in BUAA SEI



还有一种情况

- E::= Ua
- U::=a|ε (回溯?)

- a?
- E::= Ua = aa 错误
- E::= Ua = εa 正确



定义: $FOLLOW(A) = \{a \mid Z \Rightarrow ... \land a ..., a \in V_t\}$

A∈Vn , Z识别符号

该集合称为A的后继符号集合。

特殊地: 若Z ^{*}⇒...A 则 #∈FOLLOW(A)

不带回溯的充分必要条件是: 对于G的

每一个非终结符A的任意两条规则 $A:=\alpha|\beta$,下列条件成立:

- 1, $FIRST(\alpha) \cap FIRST(\beta) = \Phi$
- 2、若β= * > ε, 则FIRST(α) \cap FOLLOW(A) = Φ





4.2.3 递归子程序法 (递归下降分析法)

具体做法:对语法的每一个非终结符都编一个分析程序, 当根据文法和当时的输入符号预测到要用某个非终结符 去匹配输入串时,就调用该非终结符的分析程序。

下面通过举例说明如何根据文法构造该文法的 语法分析程序





如文法G[Z]: Z ::= UV

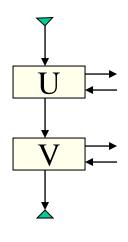
U ::=

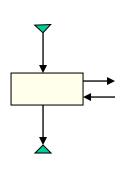
V ::=

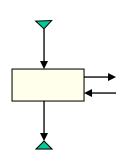
Z的分析程序

U的分析程序

V的分析程序







注: 消除左递归后, 可有其它递归:

U ::= ...U...

U ::= ...W...

W::= ...U...

例: 文法G[Z]

Z ::= ('U')'|aUb|

U∷=dZ|Ud|e

1.检查并改写文法

Z::=' ('U') '|aUb

 $U := (dZ|e)\{d\}$

改写后无左递归且首符集不相交:

 $\{(\}\cap\{a\}=\varphi$

 $\{d\}\cap\{e\}=\varphi$

2.检查文法的递归性

 $Z \Rightarrow ...U ... \Rightarrow ...Z ...$

∴Z[±]⇒ ... Z ...

 $U \Rightarrow ...Z ... \Rightarrow ...U ...$

∴U⇒... U ...

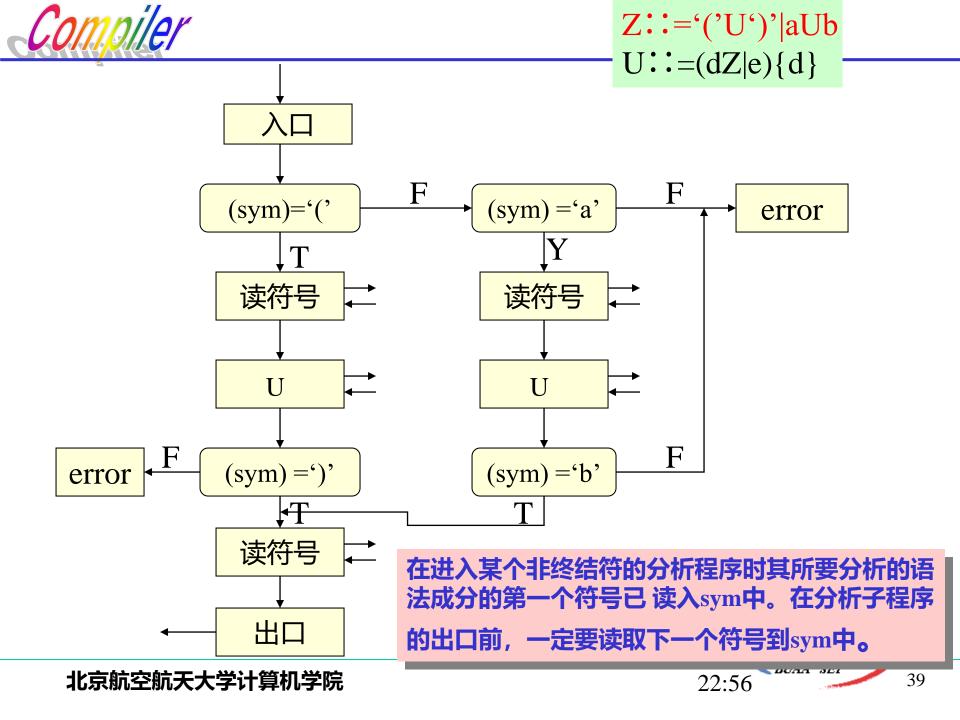
因此,Z和U的分析程序要编成递归子程序



3.算法框图

非终结符号的分析子程序的功能是: 用规则右部符号串去匹配输入串。

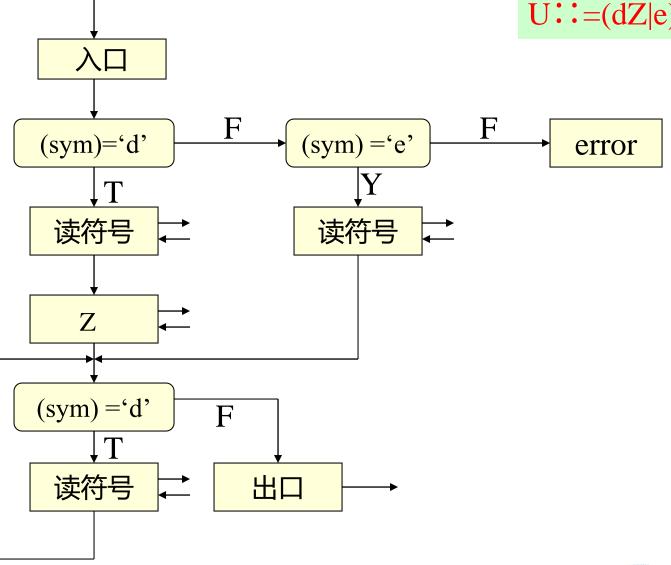
以下是以框图形式给出的两个子程序:





Z::='('U')'|aUb|

 $U := (dZ|e)\{d\}$



22:56



说明

・要注意子程序之间的接口,在程序编制时进入某个非终结 符的分析程序时其所要分析的语法成分的第一个符号已 读入sym中。

递归子程序法对应的是最左推导过程



4.2.4 用递归子程序法构造语法分析程序的例子

```
文法: <语句>::= <变量>:=<表达式>
| IF <表达式> THEN <语句>
| IF <表达式> THEN <语句> ELSE <语句>
| Section | Sectio
```



语法分析程序所要调用的子程序:

nextsym: 词法分析程序, 每调用一次读进一个单词,

单词的类别码放在sym中。

error: 出错处理程序。



END

<**语句>::= <变量>:=<表达式>**| IF<表达式>THEN<语句>[ELSE <语句>]

```
/*语句分析子程序*/
PROCEDURE state;
  IF sym ='IF' THEN
    BEGIN
       nextsym;
       expr;
       IF sym≠'THEN' THEN error
          ELSE BEGIN
                nextsym;
                state;
                IF sym='ELSE'
                  THEN BEGIN
                           nextsym;
                           state;
                         END
               END
    END
  ELSE BEGIN var;
            IF sym≠' : ='
              THEN error
              ELSE BEGIN
                      nextsym;
                      expr;
                    END
```



<变量>::= i['['<表达式>']']

```
PROCEDURE var;
  IF sym ≠'i' THEN error
     ELSE BEGIN
            nextsym;
             IF sym='[' THEN
                 BEGIN
                    nextsym;
                    expr;
                    IF sym \neq ']'
                    THEN error
                    ELSE nextsym;
                 END
           END
```

45



```
<语句>::= <变量>:=<表达式>
          | IF<表达式>THEN<语句>[ELSE <语句>]
<变量>::=i['['<表达式>']']
<表达式>::=<项>{+<项>}
<项>∷=<因子>{*<因子>}
<因子>∷=<变量>|'('<表达式>')'
                               /*表达式*/
PROCEDURE
             expr;
   BEGIN
      term;
      WHILE sym='+' DO
           BEGIN
              nextsym;
              term;
           END
   END
```

```
PROCEDURE
                               /*项*/
             term;
  BEGIN
     factor;
                              <项>::=<因子>{*<因子>}
     WHILE
            sym='*' DO
                              <因子>∷=<变量>|'('<表达式>')'
         BEGIN
           nextsym;
           factor
         END
  END;
PROCEDURE
             factor;
                                /*因子*/
  BEGIN
    IF sym='(' THEN
        BEGIN
          nextsym;
          expr;
          IF sym ≠ ')'
          THEN error
          ELSE nextsym
        END
    ELSE var;
  END
```

```
void statement()
   if (sym == IFTK) {
      getsym();
      expr();
      if (sym != THENTK)
         error();
      else {
           getsym ();
            statement ();
            if (sym == ELSETK) {
               getsym ();
               statment();
   else {
      var ();
      if (sym! = ASSIGN)
         error ();
      else {
        getsym ();
        expr();
```

```
<变量>::= i['['<表达式>']']
void var()
  if (sym != IDENFR)
     error();
  else {
         getsym ();
         if (sym == LBRACK) {
            getsym ();
            expr();
            if (sym != RBRACK)
              error ();
             else
              getsym ();
```



```
<项>∷=<因子>{*<因子>}
```

<因子>::=<变量>|'('<表达式>')'

```
void term ()
   factor();
   while (sym == MULT) {
         getsym ();
         factor ();
   void factor ()
       if (sym == LPARENT) {
             getsym ();
             expr();
             if (sym != RPARENT)
                error ();
             else getsym ();
       else var ();
```

```
void main ()
{
    getsym ();
    statement ();
}
```

```
void error ( )
{
    printf(" syntax error !\n")
}
```



<语句>::= <变量>:=<表达式>

```
|IF<表达式>THEN<语句>[ELSE <语句>]
```

```
void statement()
   if (sym == IFTK) {
      getsym();
      expr();
      if (sym != THENTK)
         error();
      else {
           getsym ();
           statement ();
           if (sym == ELSETK) {
              getsym ();
              statment();
   else {
      var ();
      if (sym! = ASSIGN)
         error ();
      else {
        getsym ();
        expr();
```

```
<变量>∷= i['['<表达式>']']
void var()
  if (sym != IDENFR)
     error();
  else {
        getsym ();
        if (sym == LBRACK) {
           getsym ();
           expr();
           if (sym != RBRACK)
             error ();
           else
              getsym ();
                 printf ("<变量>\n");
```



```
<项>::=<因子>{*<因子>}
<因子>::=<变量>|'('<表达式>')'
```

```
void term ()
                                                       void main ()
    factor();
    while (sym == MULT) {
                                                          getsym ();
          getsym ();
          factor ();
                                                          statement ();
                            printf ("<项>\n");
void factor ()
                                                      void error ()
   if (sym == LPARENT) {
          getsym ();
                                                          printf(" syntax error !\n")
          expr();
          if (sym != RPARENT)
             error ();
          else getsym ();
   else var ();
                                        printf ("<因子>\n");
                                                                              Excellence in
                                                                            BUAA SEI
                                                                                          51
                                                                    22:56
```

Compiler

举例分析

if
$$(i+i)$$
 then $i:=i*i+i$ else $i[i] := i+i[i*i]*(i+i)$

作业:

- (1) P91: 2-3
- (2) 教学平台语法分析作业